

Gradient conjugué – fonction quelconque

Algorithme de Fletcher-Reeves

• Départ : x_0 et $d_0 = - \partial f / \partial x_0$

$$x_{k+1} = x_k + \lambda_k d_k$$

avec λ_k minimisant $g(\lambda) = f(x_k + \lambda d_k)$

(défini par minimisation suivant d_k)

puis $d_{k+1} = - \partial f / \partial x_{k+1} + \beta_k d_k$

avec $\beta_k = \| \partial f / \partial x_{k+1} \|^2 / \| \partial f / \partial x_k \|^2$ tant que (cdt d'arrêt non vérifiée)

Variante de Polak – Ribière :

$$\beta_k = (\partial f / \partial x_{k+1})^T (\partial f / \partial x_{k+1} - \partial f / \partial x_k) / \| \partial f / \partial x_k \|^2$$

Méthodes du gradient conjugué: Conclusions

- Polak-Ribière équivalent au Fletcher-Reeves pour les fonctions quadratiques, mais donne des résultats différents pour des fonctions quelconques
 - Nécessite le stockage de très peu d'information :
 $d_k, \partial f / \partial x_k, \partial f / \partial x_{k+1}$ (3 vecteurs de dim. «n»)
 - Vitesse de convergence très supérieure à celle des algorithmes du gradient classiques
- => Méthode à considérer pour des problèmes de grande taille ($n > 100$)

Méthodes de Newton

- Idée : utiliser l'algorithme de Newton pour résoudre le système $\partial f / \partial x = 0$
- L'algorithme correspondant est donc

$$x_{k+1} = x_k - (\partial^2 f / \partial x_k^2)^{-1} \partial f / \partial x_k$$

- Dans le cas de fonctions quadratiques, l'algorithme converge en une seule itération
- Demeure le pb de la convergence globale si $f(x)$ est quelconque \Rightarrow on apporte les modifications suivantes

$$x_{k+1} = x_k - \lambda_k (\partial^2 f / \partial x_k^2)^{-1} \partial f / \partial x_k$$

avec λ_k minimisant $f(x)$ dans la direction $(\partial^2 f / \partial x_k^2)^{-1} \partial f / \partial x_k$

- Il se peut que localement $(\partial^2 f / \partial x_k^2)$ ne soit pas définie positive, alors

$$M_k = \mu_k I + \partial^2 f / \partial x_k^2 \text{ avec } \mu_k \text{ scalaire positif}$$

Méthodes de quasi-Newton

- Idée: Il s'agit d'une généralisation, permettant de ne pas avoir à calculer le Hessien

L'algorithme correspondant est donc

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \lambda_k \mathbf{H}_k \partial f / \partial \mathbf{x}_k$$

avec λ_k minimisant $f(\mathbf{x})$ dans la direction $\mathbf{H}_k \partial f / \partial \mathbf{x}_k$

- On veut faire *aussi bien* que Fletcher-Reeves =>

\mathbf{H}_k sera une matrice dont on impose la convergence en « n » itérations vers l'inverse du Hessien dans le cas où $f(\mathbf{x})$ est quadratique

- A l'itération « n » on se retrouve dans la configuration de la méthode de Newton et donc on converge en un coup
- D'une manière plus générale, H devra être une approximation de l'inverse du hessien

- Différentes formules peuvent être adaptées

$$H_{k+1} = H_k + \Delta_k$$

- Δ_k est une matrice de rang 1 ou 2

- Dans le cas d'une fonction quadratique, on rappelle

$$A^{-1}(\partial f / \partial x_k - \partial f / \partial x_{k-1}) = A^{-1}(Ax_k + b - Ax_{k-1} - b) = x_k - x_{k-1}$$

- On souhaite imposer la relation

$$H_{k+1}(\partial f / \partial x_k - \partial f / \partial x_{k-1}) = x_k - x_{k-1} \quad \text{soit} \quad H_{k+1} \gamma_k = \delta_k$$

- D'autre part, pour respecter la symétrie on définit

$$\Delta_k = \alpha_k u_k u_k^T \quad \text{correction de rang 1}$$

- En posant

$$\delta_k = x_k - x_{k-1} \quad \text{et} \quad \gamma_k = \partial f / \partial x_k - \partial f / \partial x_{k-1}$$

$$\Rightarrow \Delta_k = \alpha_k u_k u_k^T = (\delta_k - H_k \gamma_k)(\delta_k - H_k \gamma_k)^T / \gamma_k^T (\delta_k - H_k \gamma_k)$$

avec $\delta_k = x_k - x_{k-1}$ et $\gamma_k = \partial f / \partial x_k - \partial f / \partial x_{k-1}$

• On peut démontrer que $H_{n+1} = A^{-1}$

(convergence de la méthode de quasi Newton dans le cas quadratique en "n" itérations)

Algorithme de Fletcher-Powell

- Correction de rang 2

$$H_{k+1} = H_k + \delta_k \delta_k^T / \delta_k^T \gamma_k - H_k \gamma_k \gamma_k^T H_k / \gamma_k^T H_k \gamma_k$$

Algorithme:

$$x_{k+1} = x_k + \lambda_k d_k$$

avec λ_k minimisant $f(x)$ dans la direction $d_k = -H_k \partial f / \partial x_k$

$$H_{k+1} = H_k + \delta_k \delta_k^T / \delta_k^T \gamma_k - H_k \gamma_k \gamma_k^T H_k / \gamma_k^T H_k \gamma_k$$

et $\delta_k = x_{k+1} - x_k$ et $\gamma_k = \partial f / \partial x_{k+1} - \partial f / \partial x_k$

Algorithme de Broyden, Fletcher, Goldfrab, Shanno (BFGS)

- On sait que $H_{k+1}\gamma_k = \delta_k$
- On intervertit les rôles de γ_k et δ_k
- $G_{k+1} = G_k + \gamma_k \gamma_k^T / \gamma_k^T \delta_k - G_k \delta_k \delta_k^T G_k / \delta_k^T G_k \delta_k$
- On obtient $G_{k+1} \delta_k = \gamma_k$ à comparer avec

$$\gamma_k = H_{k+1}^{-1} \delta_k$$

Donc G_{k+1} approxime le hessien directement

La récurrence sur G_{k+1} s'inverse donc

$$(G_{k+1})^{-1} = (G_k)^{-1} + [1 + \gamma_k^T (G_k)^{-1} \gamma_k / \delta_k^T \gamma_k] * \delta_k \delta_k^T / \delta_k^T \gamma_k -$$

$$- (\delta_k \gamma_k^T (G_k)^{-1} + (G_k)^{-1} \gamma_k \delta_k^T) / \delta_k^T \gamma_k$$

Algorithme de Broyden, Fletcher, Goldfarb, Shanno (BFGS)

Et finalement

$$H_{k+1} = H_k + [1 + \gamma_k^T H_k \gamma_k / \delta_k^T \gamma_k] * \delta_k \delta_k^T / \delta_k^T \gamma_k - (\delta_k \gamma_k^T H_k + H_k \gamma_k \delta_k^T) / \delta_k^T \gamma_k$$

- Moins sensible que DFP (David Fletcher Powell) aux imprécisions de la procédure de recherche unidimensionnelle
=> permet l'utilisation de méthodes unidimensionnelles « économiques » qui nécessitent un petit nombre d'évaluations de la fonction

Grad. Conjugué : Fletcher-Reeves Quasi-Newton : BFGS

Que choisit-on?

- BFGS est beaucoup plus coûteuse en calcul
(construction matricielle à chaque itération)

N.B. On n'inverse pas la matrice, on récurse directement sur H^{-1}

- Si la valeur du vecteur qui minimise la fonction n'est pas importante => Fletcher-Reeves
- Si on veut avoir une confiance en l'estimation => BFGS
(matrice des dérivées secondes)

Comparaison des différentes méthodes. Résultats sur la convergence.

- Fait au tableau
- Conclusion:
 - Avantage des méthodes de quasi-Newton sur les méthodes du gradient conjugué en ce qui concerne le nombre de calculs de la fonction; par contre, présence de produits de matrices (calculs en n^3)

Minimisation multivariable avec contraintes.

Aspects théoriques.

I. Généralités, propriétés caractéristiques des optimums constraints

I.1. Position du problème – définition

$$\left\{ \begin{array}{l} \text{Minimiser } f(x) \\ x \in \mathcal{D} \text{ (domaine)} \end{array} \right\} \left\{ \begin{array}{l} f(x) \text{ scalaire} \\ \underline{x} \text{ vecteur en } \mathbb{R}^n, \mathcal{D} \subset \mathbb{R}^n \end{array} \right.$$

- **Contraintes (définissant \mathcal{D})**

$$\left\{ \begin{array}{l} \text{Inégalité : } g_i(x) \leq 0 \quad i=1 \dots m \\ \text{Egalité : } h_j(x) = 0 \quad j=1 \dots p \leq n-1 \end{array} \right\} \left\{ \begin{array}{l} \text{Saturées en } x_0, \text{ si } g_i(x_0) = 0 \text{ (} x_0 \text{ est sur les bords du domaine } \mathcal{D}) \\ \text{Non saturées en } x_0, \text{ si } g_i(x_0) < 0 \end{array} \right.$$

- **Minimum absolu x^***

Défini par $\forall x \in \mathcal{D}, f(x) \geq f(x^*)$ strict si l'égalité est stricte.

- **Minimum relatif x^***

\exists un voisinage $\mathcal{V}(x^*)$ tel que $\forall x \in \mathcal{D} \cap \mathcal{V}(x^*), f(x) \geq f(x^*)$

- **Point admissible**

Direction admissible en x_0

Soit x_0 admissible et une direction d

Soit $x(\alpha) = x_0 + \alpha d$, avec $\alpha \geq 0$

d est admissible $\Leftrightarrow [\exists \alpha^* > 0, \forall \alpha < \alpha^*, x(\alpha) \in \mathcal{D}]$

Remarque: Si x_0 est strictement intérieur à \mathcal{D} , toutes les directions sont admissibles.




Fig.1 Direction admissible




Fig.2 Point admissible régulier




Fig.3 Point admissible non régulier

- **Point admissible régulier** (qualification des contraintes)

x_0 est admissible régulier si les gradients des contraintes inégalité sont saturées en x_0 et ceux des contraintes égalité sont indépendants

Le gradient des contraintes est dirigé vers l'extérieur du domaine (vers les $g > 0$)

- Directions limite (ou tangente) en x_0 admissible

$\zeta(x_0)$ = ensemble des directions d telles que $[\partial h_j / \partial x_0]^T \cdot d = 0$ (pour toutes les contraintes égalité)

$[\partial d_j / \partial x_0]^T \cdot d = 0$ (pour toutes les contraintes inégalité saturées en x_0)



Fig.4 Direction tangente

But recherché:

La recherche d'un mini absolu est difficile: L'algorithme est « aveugle »

D'où recherche d'un minimum local.

Hypothèses où le mini local est un mini absolu (convexité, unimodalité)

Conditions nécessaires du 1^{er} ordre

CN1 (sans hypothèse sur la différentialité des contraintes)

Soit $f(x)$ de classe C_1

x^* mini local $\Rightarrow \exists d$ admissible en x^* , $f_{x^*}^T \cdot d \geq 0$ où f_{x^*} est le gradient de f

Interprétation géométrique:



Les déplacements dans une direction admissible ne peuvent pas faire décroître la fonction ($f(x)$) dans le sens des niveaux croissants)

Conditions nécessaires du 1^{er} ordre - suite

On peut chercher des propriétés en précisant la façon dont est défini le domaine (Kuhn & Tucker)...

Le plus évident étant $f_{x^*} = -\mu_i g_{ix^*}$ où g_{ix^*} est le gradient de g saturée et $\mu_i > 0$

Démonstration: On se déplace à partir de x^* . Soit $x(\alpha) = x^* + \alpha d$ avec $d > 0$, d admissible

Développement de Taylor

$$f[x(\alpha)] = f(x^*) + \alpha [\partial f / \partial x^*]^T \cdot dx / d \alpha + \alpha \varepsilon(\alpha)$$

$$f[x(\alpha)] = f(x^*) + \alpha [f_{x^*}^T d] + \alpha \varepsilon(\alpha)$$

$$x^* \text{ mini} \Rightarrow f[x(\alpha)] \geq f(x^*) \Rightarrow f_{x^*}^T \cdot d \geq 0$$

Cas sans contrainte

$$x^* \text{ mini} \Rightarrow f_{x^*} = 0$$

Introduction du Lagrangien pour des contraintes C_1

Cas des contraintes égalité (Conditions de Lagrange)

Min $f(x)$ contraint par $h_j(x) = 0 \quad j=1 \dots p$
 x

On définit une fonction de pénalité $\Phi(x) = \{0 \text{ si } x \text{ est admissible, } +\infty \text{ si non}\}$

Le problème contraint : $\{\text{Min } f(x), h_j(x) = 0\}$ est équivalent au problème non contraint

$$\text{Min}_{x} [f(x) + \Phi(x)]$$

Choix de la fonction de pénalité $\Phi(x)$

$$\Phi(x) = \text{Max}_{\lambda} [\sum_{j=1}^p \lambda_j h_j(x)]$$

Si x est admissible $\Phi(x)=0$

Si x est non admissible, il existe j tel que $h_j(x) \neq 0$ D'où $\text{Max}_{\lambda} [\sum_{j=1}^p \lambda_j h_j(x)] = +\infty$

Le problème non contraint auquel on est ramené s'écrit donc

$$\text{Min}_{x} [f(x) + \max_{\lambda} \sum_{j=1}^p \lambda_j h_j(x)]$$

Comme $f(x)$ est indépendant de λ , on peut écrire

$$\text{Min}_{x} [\text{Max}_{\lambda} (f(x) + \sum_{j=1}^p \lambda_j h_j(x))]$$

Le **Lagrangien** est défini par

$$L(x, \lambda) = f(x) + \sum_{j=1}^p \lambda_j h_j(x)$$

On appellera problème primal
$$\min_{x, \lambda} [\max_{\lambda} (f(x) + \sum_{j=1}^p \lambda_j h_j(x))]$$

On appellera problème dual
$$\max_{\lambda} [\min_x (f(x) + \sum_{j=1}^p \lambda_j h_j(x))]$$

Soient (x^*, λ_j^*) la solution (si elle existe) du problème (primal ou dual) sous condition de dualité forte

x^* optimum \Rightarrow Il existe $\lambda_1^* \dots \lambda_p^*$ tels que $\partial f / \partial x^* + \sum_{j=1}^p \lambda_j^* \partial h_j / \partial x^* = 0$

(Conditions de Lagrange du 1^{er} ordre)

Cas de contraintes inégalité (Conditions de Kuhn & Tucker)

$\min_x f(x), g_i(x) \leq 0, \quad i=1 \dots m$

On choisit la fonction de pénalité

$$\Phi(x) = \max_{\lambda_i \geq 0} [\sum_{i=1}^m \lambda_i g_i(x)]$$

Si x est admissible $g_i(x) \leq 0$ et $\Phi(x)=0$

Si x est non admissible, $\exists i$ tel que $g_i(x) > 0$ D'où $\max [\sum \lambda_i g_i(x)] = +\infty \quad \lambda_i \geq 0$

On appellera problème primal $\min_{x, \lambda \geq 0} [\max L(x, \lambda)]$

On appellera problème dual $\max_{\lambda \geq 0} [\min_x L(x, \lambda)]$

Soient (x^*, λ_j^*) la solution (si elle existe) du problème (primal ou dual)

x^* optimum \Rightarrow il existe $\lambda_i^* \geq 0$ tels que $\partial f / \partial x^* + \sum_{i=1}^m \lambda_i^* \partial g_i / \partial x^* = 0$

Interprétation: $\partial f / \partial x^* = - \sum \lambda_i \partial g_i / \partial x^*$


(Gradient de f = combinaison linéaire négative des contraintes)

Point selle du Lagrangien

$\min_{x, \lambda \geq 0} [\max L(x, \lambda)]$ primal

$\max_{\lambda \geq 0} [\min_x L(x, \lambda)]$ dual

Si la Lagrangien admet un point col, alors la solution du pb dual = solution du pb primal



Exemple (cas convexe) Utilisation du problème dual

- Min $f(x) = x_1^2 + x_2^2$
avec $2x_1 + x_2 \leq -4$

Lagrangien:

$$L(x, \lambda) =$$

$$\min_x L(x, \lambda) \Rightarrow$$



$$\text{Fonction duale: } \max W(\lambda) = L[x^*(\lambda), \lambda] =$$

$$\text{d'où } x_1^* = \quad , \quad x_2^* = \quad \text{et } f(x^*) = W(\lambda^*) =$$

Le problème dual est parfois beaucoup plus simple à résoudre

Conditions nécessaires du 2^e ordre

CN2 (pas d'hypothèse sur les contraintes)

Soit $f(x)$ de classe C_2

x^* mini local $\Rightarrow \forall d$ admissible en x^* , $f_{x^*}^T d \geq 0$ où f_{x^*} est le gradient de f

Et si $f_{x^*}^T d = 0$, alors $d^T F_{xx}^* d \geq 0$ (F_{xx}^* traduit la courbure vers le haut ou le bas)

Démonstration:

x^* mini local $\Rightarrow \forall d$ admissible $f_{x^*}^T d \geq 0$ déjà démontré en CN1

Si $f_{x^*}^T d = 0$, alors

$$f[x(\alpha)] = f(x^*) + \alpha \cdot 0 + \frac{1}{2} \alpha^2 d^T F_{xx}^* d + \alpha^2 \varepsilon(\alpha)$$

$$f[x(\alpha)] \geq f(x^*) \Rightarrow d^T F_{xx}^* d \geq 0 \text{ pour tout } d \text{ admissible}$$

On peut chercher des propriétés en précisant la façon dont est défini le domaine (Kuhn & Tucker)...

Cas sans contraintes

$$x^* \text{ opt} \Rightarrow f_{x^*} = 0, F_{xx}^* \geq 0$$

Conditions suffisantes du 2nd ordre (fonction et contraintes de classe C_2)

Conditions suffisantes du 2^e ordre

Introduction du Lagrangien du problème

Minimiser $f(x)$ contraint par

$$g_i(x) \leq 0 \quad i=1 \dots m$$

$$h_j(x) = 0 \quad j=1 \dots p \leq n-1$$

$$L(x, \mu_i, \lambda_j) = f(x) + \sum \mu_i g_i(x) + \sum \lambda_j h_j(x)$$

C.S.2 Il existe un lot de λ_j un lot de μ_i positionnels

tels que

$$(1) \sum \mu_i g_i(x^*) = 0 \quad (2) L_{x^*} = (x^*, \mu_i, \lambda_j) = 0 \quad (3) d^T L_{xx}^* d \geq 0 \text{ pour tout } d \in \zeta(x^*)$$

Alors x^* est minimum local.

Remarques générales sur CS2

1) $\nabla \mu_i g_i(x^*) = 0 \Rightarrow$ prendre les μ_i nuls pour les contraintes non actives

$$2) L_{x^*} = (x^*, \mu_i, \lambda_j) = 0 \Rightarrow f_x(x^*) = - \sum \mu_i g_i(x^*) - \sum \lambda_j h_j(x^*)$$

Illustration (en l'absence de h_j)

$-f_x(x^*)$ se décompose dans composantes > 0 sur g_{1x} et g_{2x} (strictement)

descente de $f \Rightarrow$ sortie du domaine

3) Il s'agit bien d'un minimum et non d'un maximum

Remarque sur CS2 quand x^* est régulier

- Quand x^* est régulier, les conditions (1) et (2) sont appelées conditions nécessaires de K.T. du 1er ordre

Cas sans contraintes:

$f'_x(x^*) = 0$ et $F_{xx}(x^*) > 0 \Rightarrow x^*$ est minimum local

Méthodes primales

- Les méthodes primales cherchent à résoudre le problème directement, et
 - 1) engendrent une suite de points satisfaisant les contraintes
 - 2) correspondent à une suite décroissante des valeurs de la fonction
- En cas d'arrêt de la procédure, le point courant peut être pris comme approximation de l'optimum recherché.

I.1 Méthodes de changement de variable:

$$a \leq x \leq b \quad \Rightarrow \quad x = a + (b-a)\sin^2(y)$$

On remplace x par une variable non contrainte y

I.2 Méthodes des directions admissibles (Zoutendijk, Topkins et Veinott)

- x_0 le point de départ satisfaisant les contraintes
- I_0 l'ensemble des indices des contraintes saturées en X_0

On cherche une direction admissible d

On doit avoir $(\partial g_j / \partial x_0) \cdot d \leq 0$

(afin que le déplacement ne rende aucune contrainte saturée positive)

D'autre part la fonction doit diminuer lors d'un déplacement

$$(\partial f / \partial x_0)^T \cdot d < 0$$

Idée : $\text{Min } (\partial f / \partial x_0)^T \cdot d < 0$

contraint par $(\partial g_j / \partial x_0) \cdot d \leq 0 \quad i \in I_0$

$$\sum |d| = 1$$

Inconvénients:

- Tout déplacement suivant d peut faire sortir du domaine

Exemple

- Un petit déplacement peut changer le nombre de contraintes saturées et entraîner une discontinuité brusque de la direction

Exemple (fait au tableau)

=> Raffinements de la méthode précédente (Topkins et Veinott)
Tenir compte de toutes les contraintes (saturées + non saturées)

II.2 Méthodes de pénalité avec paramètres

- Pénalité à point intérieur : la proximité des contraintes est pénalisée avec un poids de moins en moins grand
- Min $f(x)$ avec $g_i(x) > 0$ et X_0 point de départ admissible
- Min $\theta(x, r_k) = f(x) + r_k \sum 1/g_i(x)$ avec r_k suite décroissante vers zéro
x

Illustration: (faite au tableau)

II.2 Méthodes de pénalité avec paramètres

- Pénalité à point extérieur : la non satisfaction des contraintes est pénalisée avec un poids de plus en plus grand
- $\text{Min } f(x)$ avec $g_i(x) > 0$ et X_0 point de départ, non nécessairement admissible
- $\text{Min}_x F(x, r_k) = f(x) + 1/r_k \sum \{\text{Min}[0, g_i(x)]\}^2$ avec r_k suite décroissante

II.2 Méthodes de pénalité avec paramètres

- Méthodes mixtes

- Min $f(x)$ avec

$$g_i(x) > 0 \quad i=1 \dots m$$

$$h_j(x) = 0 \quad j=1 \dots p$$

On décompose $h_j(x) = 0 \iff h_j(x) > 0, j=1 \dots p$ et $h_j(x) \leq 0, j=1 \dots p$

on note $g_i(x) > 0 \quad i=m+1, \dots, m+1+2p$

Soit en posant $q=m+1+2p$

- Min $F(x, r_k) = f(x) + r_k \sum_{i=1}^n 1/g_i(x) + 1/r_k \sum_{i=n+1}^q \{\text{Min}[0, g_i(x)]\}^2$ avec r_k suite décroissante vers 0

1^{er} terme : inégalités impératives 2^{eme} terme : inégalités non impératives (tjs vérifiées) et contraintes égalité